

I. CARGA Y EXPLORACIÓN INICIAL

1.1 Carga de DataSet - Online Retail.csv

```
import pandas as pd, inspect
import numpy as np

try:
    df = pd.read_csv("https://raw.githubusercontent.com/leonelp399/Retail-Dataset--MCD/main/Online%20Retail.csv", sep=";")
    print(f" Datos cargados exitosamente")
except Exception as e:
    print(f"X Error al cargar datos: {e}")
```

Datos cargados exitosamente

```
display(df.head())
```

	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
0	536365	85123A	WHITE HANGING HEART T-LIGHT HOLDER	6	1/12/2010 08:26	2.55	17850.0	United Kingdom
1	536365	71053	WHITE METAL LANTERN	6	1/12/2010 08:26	3.39	17850.0	United Kingdom
2	536365	84406B	CREAM CUPID HEARTS COAT HANGER	8	1/12/2010 08:26	2.75	17850.0	United Kingdom
3	536365	84029G	KNITTED UNION FLAG HOT WATER BOTTLE	6	1/12/2010 08:26	3.39	17850.0	United Kingdom
4	536365	84029E	RED WOOLLY HOTTIE WHITE HEART.	6	1/12/2010 08:26	3.39	17850.0	United Kingdom

Observaciones:

InvoiceNo

Corresponde al número de factura que identifica cada transacción.

StockCode

Representa el código de stock asociado a cada producto.

Description

Contiene la descripción del producto. Dado que no existe un código de producto, podría considerarse como identificador alternativo.

Quantity

Indica la cantidad de unidades del producto adquiridas en la transacción.

InvoiceDate

Registro de fecha y hora en que se emitió la factura.

UnitPrice

Indica el precio unitario del producto.

CustomerID

Es el identificador único asignado a cada cliente.

Country

Señala el país de origen del cliente.

```
print("Cantidad de Filas: ", df.shape[0])
print("Cantidad de Columnas o Variables: ", df.shape[1])
```

```
Cantidad de Filas: 541909
Cantidad de Columnas o Variables: 8
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 541909 entries, 0 to 541908
Data columns (total 8 columns):
#   Column          Non-Null Count  Dtype
---  -
0   InvoiceNo        541909 non-null object
1   StockCode       541909 non-null object
2   Description     540455 non-null object
3   Quantity        541909 non-null int64
4   InvoiceDate     541909 non-null object
5   UnitPrice       541909 non-null float64
6   CustomerID      406829 non-null float64
7   Country         541909 non-null object
dtypes: float64(2), int64(1), object(5)
memory usage: 33.1+ MB
```

En valores numéricos tenemos Quantity, UnitPrice y CustomerId
 En valores object's tenemos las demás variables que puede ser de tipo Date y String

```
df.describe()
```

	Quantity	UnitPrice	CustomerId
count	541909.000000	541909.000000	406829.000000
mean	9.552250	4.611114	15287.690570
std	218.081158	96.759853	1713.600303
min	-80995.000000	-11062.060000	12346.000000
25%	1.000000	1.250000	13953.000000
50%	3.000000	2.080000	15152.000000
75%	10.000000	4.130000	16791.000000
max	80995.000000	38970.000000	18287.000000

1.2 Análisis de datos erróneos

Se creó la función analisis_datos, la cual evalúan los siguientes criterios:

- Valores faltantes
 Genera un DataFrame que muestra la cantidad y el porcentaje de valores nulos por variable, permitiendo identificar variables con información vacía.

- Duplicados

Detecta registros duplicados mediante el método duplicated().

- Valores negativos o cero

Analiza las columnas Quantity y UnitPrice para identificar registros con valores negativos o iguales a cero. Esta verificación se incluyó debido a que, al aplicar df.describe(), se observó la presencia de en los valores mínimos como negativos, no tiene sentido realizar ventas con precio o cantidad de unidad negativo o igual a cero.

- Transacciones canceladas

Identifica facturas canceladas analizando la columna InvoiceNo, cuyo tipo de dato es object, presenta el carácter "C" al inicio del número de factura. Estos registros corresponden a transacciones canceladas, también indicar que las cantidades de producto aparecen con valores negativos en dichas filas

Salida del Análisis de Datos

1) VALORES FALTANTES

Columna	Valores Faltantes	Porcentaje
InvoiceNo	0	0.0000
StockCode	0	0.0000
Description	1454	0.2683
Quantity	0	0.0000
InvoiceDate	0	0.0000
UnitPrice	0	0.0000
CustomerID	135080	24.9267
Country	0	0.0000

2) DUPLICADOS EXACTOS: 5,268

3) CANCELACIONES: 9,288 (1.71%)

Rango Quantity canceladas: [-80995, -1]

- Cancelaciones con PAR encontrado: 2,883
- Cancelaciones SIN par: 6,405
- Ventas emparejadas: 2,883

4) NEGATIVOS / CERO (excluye cancelaciones)

- Quantity <= 0 : 1,336 (0.25%)
- UnitPrice<= 0 : 2,517 (0.47%)

Cantidad de registros que presentan valor vacío en las variables Description y CustomerID

```
df_data_faltante = df[df['Description'].isnull() & df['CustomerID'].isnull()]
print(f'Cantidad de registro con valor nulo en Description y CustomerID \n{len(df_data_faltante)}')
```

```
Cantidad de registro con valor nulo en Description y CustomerID
1454
```

Observamos

- Se identificó que 9,288 registros corresponden a transacciones canceladas, lo que representa aproximadamente el 1.7 % del total. Asimismo, se observó que los valores faltantes en la variable Description (1,454 casos) coinciden con valores nulos en CustomerID, lo que sugiere una relación directa entre ambas variables, posiblemente asociada a registros incompletos o anulados.
- se detectaron 5,268 registros duplicados y un 24.9 % de observaciones con CustomerID faltante, lo cual refuerza la necesidad de una depuración previa al análisis, especialmente para garantizar la coherencia entre los identificadores de clientes y las descripciones de los productos.

1.3 Depuración de datos erróneos

```
1) Filas sin CustomerID eliminadas: 135,080
2) Duplicados exactos eliminados: 5,225
3) Pares venta↔crédito eliminados (ambas filas): 2,758
pares
4) Cancelados restantes eliminados: 6,114
5) Filas con Quantity<=0 o UnitPrice<=0 eliminadas: 40

— Resumen —
Registros iniciales : 541,909
Registros finales   : 389,934 (72.0% del original)
```

Observamos

Se ejecutó la depuración conforme al análisis de calidad previo, eliminándose 151,975 registros (≈ 28.0 % del total inicial de 541,909). El detalle es:

- Filas sin CustomerID: 135,080 (24.93 %).
- Duplicados exactos: 5,225 (0.96 %).
- Pares venta ↔ créditos eliminados (ambas filas): 2,758 pares = 5,516 filas (1.02 %).
- Cancelaciones restantes (sin par): 6,114 (1.13 %).
- Valores no válidos ($\text{Quantity} \leq 0$ o $\text{UnitPrice} \leq 0$, excluye cancelaciones): 40 (0.01 %).


Como resultado, el dataset final queda en 389,934 registros (≈ 72.0 % del original), con menor ruido por anulaciones, duplicados y claves de cliente vacías, y preparado para un EDA y modelado más confiables.

II. Análisis de distribución

2.1 Histogramas


Considerando los valores de cantidad de registros, media, desviación estándar, valor mínimo, cuartil 1, cuartil 2, cuartil 3, valor máximo, skewness y kurtosis

	UnitPrice	Quantity
count	389934.000	389934.000
mean	3.075	12.640
std	21.322	42.264
min	0.001	1.000
25%	1.250	2.000
50%	1.950	6.000
75%	3.750	12.000
max	8142.750	4800.000
skew	224.212	29.951
kurt	67738.956	1789.301



Observamos

- UnitPrice muestra una asimetría positiva extrema (skew = 224; kurtosis $\approx 67,739$). La masa de datos se concentra en precios bajos (Q1 = 1.25, mediana = 1.95, Q3 = 3.75) y existe una cola muy larga con valores aislados hasta 8,142.75. Esto sugiere outliers severos (posibles errores de captura, unidades distintas, costos de envío o packs).



Observamos


- Quantity también presenta asimetría positiva pronunciada ($\text{skew} = 29.95$; $\text{kurtosis} \approx 1,789$). La mayoría de las líneas son pedidos pequeños ($Q1 = 2$, mediana = 6, $Q3 = 12$; media = 12.64) con una cola larga de pedidos muy grandes (máx. = 4,800).

2.2 BoxPlot – Outliers

Se considero trabajar con tukey, con el objetivo de trabajar los outliers con los valores cuartílicos


	Variable	Cantidad	Q1	Q3	IQR	LowerFence	UpperFence	Outliers Totales	Pct Outliers	Max Outlier
0	UnitPrice	389934	1.25	3.75	2.5	-2.5	7.5	33501	8.591	8142.75
1	Quantity	389934	2.00	12.00	10.0	-13.0	27.0	25264	6.479	4800.00

Calculando los valores de lowerFence y UpperFence que son los limites para considerar valores como outliers, la cantidad de outliers total y su porcentaje y el máximo valor del outlier.



Observamos

- 8.59 % de outliers, todos por arriba del límite, a simple vista podemos observar que hay valores de precio mayores a los 3000, podría considerar realizar un análisis desde los valores mayores a 1000
- Revisar si son artículos premium o errores de carga



Observamos

- 6.48 % de outliers, todos por arriba del límite, podemos observar cantidades de unidades muy por encima de 3000

2.3 Definición de Variable Objetivo y Creación de Nuevas Variables

Considerando que la variable objetivo será Revenue (Ganancia) (resultado del producto entre Quantity y UnitPrice), esta permitirá realizar un análisis detallado del comportamiento de las ventas y el desempeño comercial.

A partir de esta variable, es posible desarrollar los siguientes análisis:

- Distribución de ingresos por país, cliente o periodo temporal (mes, año).
- Identificación de los productos más rentables y su contribución a las ventas totales.
- Análisis temporal de las horas y días con mayor volumen de ventas.

También realizamos la creación de las siguientes variables (Year, Month, MonthName, DayOfWeek, Hour, YearMonth y is_cancel) para que nos apoye en el análisis.

	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID	Country	is_cancel	Year	Month	MonthName	DayOfWeek	Hour	YearMonth	Revenue
0	536365	85123A	WHITE HANGING HEART T-LIGHT HOLDER	6	2010-12-01 08:26:00	2.55	17850.0	United Kingdom	False	2010	12	December	Wednesday	8	2010-12	15.30
1	536365	71053	WHITE METAL LANTERN	6	2010-12-01 08:26:00	3.39	17850.0	United Kingdom	False	2010	12	December	Wednesday	8	2010-12	20.34
2	536365	84406B	CREAM CUPID HEARTS COAT HANGER	8	2010-12-01 08:26:00	2.75	17850.0	United Kingdom	False	2010	12	December	Wednesday	8	2010-12	22.00
3	536365	84029G	KNITTED UNION FLAG HOT WATER BOTTLE	6	2010-12-01 08:26:00	3.39	17850.0	United Kingdom	False	2010	12	December	Wednesday	8	2010-12	20.34
4	536365	84029E	RED WOOLLY HOTTIE WHITE HEART.	6	2010-12-01 08:26:00	3.39	17850.0	United Kingdom	False	2010	12	December	Wednesday	8	2010-12	20.34


2.4 Distribución de la variable objetivo

```
y = df_clean["Revenue"].dropna()

desc = {
    "count": y.size,
    "mean": y.mean(),
    "median": y.median(),
    "std": y.std(),
    "p01": y.quantile(0.01),
    "p25": y.quantile(0.25),
    "p50": y.quantile(0.50),
    "p75": y.quantile(0.75),
    "p99": y.quantile(0.99),
    "skew": skew(y),
    "kurtosis": kurtosis(y, fisher=True)
}


pd.Series(desc).round(3)
```

count	389934.000
mean	21.765
median	11.900
std	94.866
p01	0.550
p25	4.950
p50	11.900
p75	19.800
p99	201.600
skew	190.639
kurtosis	73426.157



Observamos

- Revenue presenta asimetría positiva marcada. La masa principal se concentra entre ≈ 5 y 20 ($Q1=4.95$, mediana= 11.9 , $Q3=19.8$). La media (21.77) queda por encima de la mediana, arrastrada por la cola derecha. El recorte 1–99% permite ver el “cuerpo” de la distribución sin que los extremos dominen la escala.




	Variable	Cantidad	Q1	Q3	IQR	LowerFence	UpperFence	Outliers Totales	Pct Outliers	Max Outlier
0	Revenue	389934	4.95	19.8	14.85	-17.325	42.075	30747	7.885	38970.0

Observamos

- La mayoría de las ventas se concentra entre 4.95 ($Q1$) y 19.80 ($Q3$); la mediana es alrededor de 11.9.
- Con la regla de Tukey, el límite superior del rango normal es aproximadamente 42.08; el inferior sería negativo y no aplica porque Revenue es ≥ 0 .

- Hay 30,747 outliers (7.89% del total), todos por encima del límite superior.
- Se observan valores extremos de varios miles (en el gráfico aparecen hasta ~38970), por lo que la media queda inflada respecto a la mediana.


2.5 Comparar distribuciones



Observamos

- Patrón estable: Las distribuciones son muy similares entre meses: Q1 ~4–6, mediana ~10–15, Q3 ~18–20. La forma se mantiene sesgada a la derecha (la media > mediana en todos los meses).
- Meses con media más alta: Mayo, Junio, Agosto y Septiembre (≈ 24).
- Meses con media más baja: Noviembre (≈ 18)
- Dispersión similar: La amplitud intercuartílica es prácticamente la misma; los boxplots llegan hasta ~20 y los bigotes (Tukey) ~40, indicando variabilidad comparable entre meses.


Implicación: No se observa una estacionalidad fuerte en la parte central de la distribución; las diferencias son moderadas. Para acciones comerciales, priorizar Jun–Sep (ligeramente superiores)



Observamos

- Patrón laboral estable: De lunes a viernes las distribuciones son muy parecidas: $Q1 \approx 5-6$, mediana $\approx 12-15$, $Q3 \approx 20$; la media se mantiene por encima de la mediana (sesgo a la derecha).
- Picos de media: Jueves (25) es el más alto, seguido de martes y viernes (24).
- Fin de semana más débil: Domingo cae con media ~ 13 , mediana ~ 7 y $Q1$ bajo (≈ 3), indicando tickets más pequeños y/o menos transacciones.
- Dispersión comparable: Los rangos intercuartílicos son similares entre días; los bigotes llegan ~ 40 , sugiriendo colas superiores en todos los casos.

Implicación: No hay estacionalidad fuerte intrasemanal en el centro de la distribución, pero sí un efecto fin de semana claro. Para campañas o recursos operativos, priorizar jueves–viernes (mayor ingreso promedio) y considerar promociones o tácticas específicas para domingo.



Observamos

- Una concentración marcada en las primeras horas del día, con un pico muy alto alrededor de las 7:00 a.m., donde se registra el promedio más


elevado de ganancias (82). Después de esa hora, los ingresos disminuyen de forma pronunciada y se mantienen relativamente bajos y estables durante el resto del día, con una leve subida en las 6:00 p.m. (36). Este comportamiento sugiere que la mayor actividad comercial ocurre temprano en la mañana, posiblemente por procesos automáticos, ventas programadas o aperturas de jornada, mientras que el resto del día muestra un flujo regular y sostenido pero menor de transacciones.

III. Análisis de correlaciones

3.1 Correlaciones con variables numéricas

Correlaciones SPEARMAN con Revenue (Ganancia):

	rho	intensidad
Revenue	1.000	muy fuerte
Quantity	0.652	fuerte
UnitPrice	0.349	moderada
Year	0.006	nula
Month	-0.070	nula
Hour	-0.169	débil




Observamos

- El mapa y el ranking Spearman indican que Revenue está explicado sobre todo por Quantity ($\rho \approx 0.65$, relación fuerte) y en menor medida por

UnitPrice ($p \approx 0.35$, moderada). Las variables temporales tienen poca o nula asociación con la ganancia a nivel transacción: Hour muestra una relación débil y negativa ($p \approx -0.17$) y Month/Year son casi nulas. Además, se aprecia una relación inversa moderada entre Quantity y UnitPrice ($p \approx -0.41$), consistente con compras de mayor volumen a menor precio (descuentos/paquetes). En resumen: el volumen vendido es el principal driver del Revenue, con el precio aportando en segundo plano y el calendario aportando poco en esta granularidad.

3.2 Multicolinealidad de variables


	Variable	VIF	Nivel
4	Month	1.134327	Baja
5	Year	1.130811	Baja
3	Hour	1.005643	Baja
1	Quantity	1.002907	Baja
2	UnitPrice	1.000383	Baja



Observamos, que no hay multicolinealidad preocupante.

- El gráfico de VIF (Factor de Inflación de la Varianza) muestra que no existe multicolinealidad significativa entre las variables predictoras numéricas (Quantity, UnitPrice, Hour, Month y Year). Todos los valores se encuentran alrededor de 1.0 a 1.13, muy por debajo del umbral crítico de 5, lo que indica que ninguna variable está explicando a otra de forma redundante.
- Esto significa que los predictores son independientes entre sí y pueden usarse simultáneamente en modelos estadísticos sin riesgo de distorsionar los coeficientes ni inflar los errores estándar. En síntesis, el conjunto de variables numéricas es estable y adecuado para modelado predictivo.

3.3 Scatter plots




Observamos

- El diagrama de dispersión muestra una relación no lineal y altamente concentrada, donde la mayoría de los países presentan valores de Revenue muy bajos y agrupados cerca del eje vertical, mientras que unos pocos puntos se alejan hacia la derecha, indicando ventas de alto valor.
- No se aprecia relación lineal entre país e ingreso, ya que los puntos no siguen una tendencia ascendente o descendente continua, pero sí se observa un patrón de dispersión desigual: el Reino Unido concentra la mayor cantidad de transacciones y amplitud de ingresos, mientras que otros países forman pequeños clústeres compactos con menor variabilidad.
- El resto de los países como Francia, Alemania, Países Bajos y Australia muestran volúmenes mucho menores y dispersión limitada, indicando que sus mercados son más pequeños o tienen menor frecuencia de compra. En resumen, el gráfico evidencia una concentración geográfica significativa de las ventas, dominada por el Reino Unido, con pocos países que aportan ingresos relevantes y una larga cola de mercados marginales con escasa participación.

IV. Visualizaciones avanzadas


4.1 Pairplot de variables principales



Observamos

- Se observa una fuerte concentración de puntos en valores bajos para todas las variables y colas largas (outliers) en Revenue, Quantity y UnitPrice. El color por RevenueTier muestra que los casos Altos se ubican sobre todo en cantidades elevadas (y a veces con UnitPrice mayor), confirmando que el ingreso alto proviene principalmente de volumen y, en menor medida, de precio. Entre Quantity y UnitPrice se aprecia una relación inversa (compras grandes tienden a precios unitarios más bajos), mientras que Revenue vs Quantity sugiere asociación positiva no lineal. La variable Year está prácticamente concentrada en 2011, sin patrón diferenciador por tier. En conjunto: distribución muy asimétrica, presencia de outliers, y el volumen vendido como driver clave del revenue.

4.2 Gráficos de densidad



Observamos

- Las curvas de densidad (recortadas al 1–99%) muestran distribuciones asimétricas a la derecha en todos los países: muchas transacciones de bajo Revenue y una cola larga de tickets altos. United Kingdom presenta una densidad más alta y más cercana a valores pequeños, indicando mayor frecuencia de pedidos de bajo monto (mercado de volumen). Germany, France, EIRE y Spain comparten una forma similar pero con el pico desplazado un poco a la derecha, sugiriendo un ticket típico algo mayor que el de UK. En todos los casos persisten colas derechas que reflejan ventas ocasionales de alto valor.

V. Actividades


5.1 Ticket promedio por transacción

```
ticket_por_factura = (  
    df_clean.groupby('InvoiceNo', as_index=False)['Revenue'].sum()  
    .rename(columns={'Revenue': 'Ticket'})  
)  
  
ticket_promedio = ticket_por_factura['Ticket'].mean()  
print(f" Ticket promedio por transacción: {ticket_promedio:,.2f}")  
  
Ticket promedio por transacción: 461.27
```

Se calculó el valor promedio de la Ganancia o Ticket (variable Revenue) para toda la población, obteniendo el valor de 461.27

Posteriormente se calculó los valores promedios pero clasificados por país de Consumer


	Revenue
Country	
Singapore	3037.69
Netherlands	3032.30
Australia	2545.82
Japan	1963.91
Lebanon	1693.88
Israel	1443.17
Brazil	1143.60
Switzerland	1097.53
Sweden	1051.94
Denmark	1045.85
Norway	1029.43
RSA	1002.31
EIRE	996.20
Greece	952.10
Cyprus	885.11
Channel Islands	805.90
Spain	650.36
United Arab Emirates	634.09
Iceland	615.71
Canada	611.06
Austria	599.92
Portugal	577.65
USA	576.97
Finland	546.98
Malta	541.14
France	533.39
Germany	496.79
Italy	453.47
Belgium	419.21
United Kingdom	418.36



Observamos

- El diagrama AOV vs # de facturas confirma dos perfiles claros: Reino Unido está en el cuadrante de alto volumen y bajo ticket (muchísimas facturas, pero AOV ≈ 418 , por debajo del promedio global 461), por eso su burbuja es la más grande (mayor revenue total). En cambio, Singapur y Países Bajos se ubican en alto AOV y bajo volumen ($\approx 3.0k$ por factura), seguidos por Australia ($\approx 2.5k$), es decir, mercados premium con pocas transacciones, pero de alto valor. Francia y Alemania aparecen con volumen medio/alto y AOV bajo-medio (~ 500). En conjunto, el negocio se sostiene por volumen en UK, mientras que el crecimiento de valor proviene de países premium donde conviene impulsar adquisición en UK.

5.2 Identificar productos más vendidos por mes





	YearMonth	StockCode	Description	Quantity	Revenue	n_invoices	rank_qty
0	2010-12	84077	WORLD WAR 2 GLIDERS ASSTD DESIGNS	5139	1150.47	29	1.0
1	2011-01	85123A	WHITE HANGING HEART T-LIGHT HOLDER	3531	10040.55	154	1.0
2	2011-02	22053	EMPIRE DESIGN ROSETTE	3986	3302.92	4	1.0
3	2011-03	85099B	JUMBO BAG RED RETROSPOT	4924	8496.88	119	1.0
4	2011-04	84077	WORLD WAR 2 GLIDERS ASSTD DESIGNS	10224	2281.44	38	1.0
5	2011-05	22197	SMALL POPCORN HOLDER	6730	4971.70	73	1.0
6	2011-06	85099B	JUMBO BAG RED RETROSPOT	3529	6628.42	126	1.0
7	2011-07	84077	WORLD WAR 2 GLIDERS ASSTD DESIGNS	3552	968.64	38	1.0
8	2011-08	84879	ASSORTED COLOUR BIRD ORNAMENT	6417	9652.41	102	1.0
9	2011-09	85099B	JUMBO BAG RED RETROSPOT	4175	7987.85	183	1.0
10	2011-10	84077	WORLD WAR 2 GLIDERS ASSTD DESIGNS	8078	1926.14	56	1.0
11	2011-11	23084	RABBIT NIGHT LIGHT	12334	23152.97	435	1.0
12	2011-12	22197	POPCORN HOLDER	5362	3992.20	48	1.0

Observamos

- El gráfico muestra la evolución de los productos más vendidos por mes en función de la cantidad total despachada (Quantity), revelando las variaciones en la demanda a lo largo del periodo analizado. Se observa que los productos con mayores volúmenes corresponden a artículos de regalo o decoración, como “World War 2 Gliders Asstd Designs”, “Medium Ceramic Top Storage Jar” y “Rabbit Night Light”, que destacan como los más vendidos en distintos meses. La tendencia sugiere un comportamiento estacional de las ventas, con picos notables en abril y noviembre, posiblemente asociados a campañas de primavera y fin de año, mientras que en los meses intermedios las ventas mantienen niveles moderados. En general, el patrón evidencia una rotación constante de productos líderes, lo que indica una diversidad en la preferencia del consumidor y la importancia de mantener un portafolio variado para sostener las ventas.

5.3 Patrones de compra por país







Observamos

- En conjunto, los gráficos confirman dos perfiles claros: UK domina el volumen de ingresos mes a mes (picos en sep–nov), pero con ticket promedio (AOV) bajo y estable, es decir, su liderazgo se explica por muchas facturas más que por valor por pedido. Por el contrario, Singapore, Netherlands y Australia exhiben AOV alto y volátil (picos puntuales), pero con volumen pequeño; Francia y Alemania se mantienen en niveles moderados y estables en ambas métricas. En síntesis: el crecimiento total proviene del volumen en UK, mientras que el valor unitario está en mercados “premium”; tácticamente, upsell/bundles en UK

5.4 Clientes de alto valor (RFM básico)




	CustomerID	CountryDominant	Recency	Frequency	Monetary	R	F	M	RFM_Score
0	14646.0	Netherlands	1	73	279846.02	4	4	4	12
1	18102.0	United Kingdom	0	60	259657.30	4	4	4	12
2	17450.0	United Kingdom	8	45	189607.53	4	4	4	12
3	14911.0	EIRE	1	198	137166.67	4	4	4	12
4	14156.0	EIRE	9	55	114516.28	4	4	4	12
5	17511.0	United Kingdom	2	30	88556.38	4	4	4	12
6	16684.0	United Kingdom	4	28	65920.12	4	4	4	12
7	14096.0	United Kingdom	4	17	65164.79	4	4	4	12
8	13694.0	United Kingdom	3	50	63555.30	4	4	4	12
9	15311.0	United Kingdom	0	90	59857.16	4	4	4	12
10	13089.0	United Kingdom	2	96	58308.68	4	4	4	12
11	17949.0	United Kingdom	1	41	54530.94	4	4	4	12
12	15061.0	United Kingdom	3	48	54391.94	4	4	4	12
13	15769.0	United Kingdom	7	25	52002.72	4	4	4	12
14	14298.0	United Kingdom	8	44	51527.30	4	4	4	12
15	14088.0	United Kingdom	10	13	50415.49	4	4	4	12
16	17841.0	United Kingdom	1	124	40018.75	4	4	4	12
17	13798.0	United Kingdom	1	57	36910.49	4	4	4	12
18	16013.0	United Kingdom	3	46	35639.60	4	4	4	12
19	16422.0	United Kingdom	17	50	34651.40	4	4	4	12



Observamos

- Se ve una cartera bimodal: el Top 20 por Monetary está dominado en número por United Kingdom, pero los tickets acumulados más altos provienen de clientes puntuales de Netherlands y EIRE (picos >200k), es decir, pocas cuentas muy grandes fuera de UK. Al mirar el % de clientes de alto valor (RFM ≥ 10) por país, mercados pequeños como Iceland y Singapore concentran casi todos sus clientes en el segmento premium (probable N bajo), mientras que UK, pese a su tamaño, solo tiene ~29% de alto valor: mucho volumen pero menor valor unitario. Implicación: priorizar fidelización/VIP en Netherlands/EIRE/Singapore


5.5 Evolución de ventas semanales



Observamos

- El gráfico muestra la evolución semanal del ingreso total (Revenue) y evidencia un comportamiento cíclico con tendencia creciente hacia el último trimestre de 2011. Durante las primeras semanas, los ingresos presentan alta volatilidad, con caídas marcadas que podrían corresponder a semanas de baja demanda o ajustes operativos. A partir de mediados de año, la serie muestra una recuperación sostenida y mayor estabilidad, y entre septiembre y noviembre se observa el pico más alto, coincidente con la temporada de compras de fin de año (Black Friday, Navidad, etc.). En resumen, el patrón sugiere una aceleración progresiva en las ventas con estacionalidad positiva al cierre del año, reflejando oportunidades para reforzar estrategias de marketing y abastecimiento en esos meses clave.

5.6 Identificar productos con mayor cancelación



	StockCode	QtyVendida	QtyCancelada	CancelRate	Description
1954	23055	260	432.0	1.661538	IVORY CHANDELIER T-LIGHT HOLDER
2731	47566B	1082	1424.0	1.316081	TEA TIME PARTY BUNTING
2505	23843	80995	80995.0	1.000000	PAPER CRAFT , LITTLE BIRDIE
3029	84347	9476	9376.0	0.989447	ROTATING SILVER ANGELS T-LIGHT HLDR
2059	23166	78033	74494.0	0.954647	MEDIUM CERAMIC TOP STORAGE JAR
3642	85232B	280	255.0	0.910714	SET OF 3 BABUSHKA STACKING TINS
1956	23057	496	433.0	0.872984	BEADED CHANDELIER T-LIGHT HOLDER
1955	23056	756	579.0	0.765873	FLOWERS CHANDELIER T-LIGHT HOLDER
3420	85023B	105	73.0	0.695238	EAU DE NILE JEWELLED PHOTOFRAME
740	21655	55	36.0	0.654545	HANGING RIDGE GLASS T-LIGHT HOLDER
2854	72802B	738	454.0	0.615176	OCEAN SCENT CANDLE IN JEWELLED BOX
4049	M	7230	4066.0	0.562379	Manual
2706	47351B	86	48.0	0.558140	BLUE VOILE LAMPSHADE
81	16259	213	108.0	0.507042	PIECE OF CAMO STATIONERY SET
3214	84754	316	144.0	0.455696	S/15 SILVER GLASS BAUBLES IN BAG
1822	22920	3427	1527.0	0.445579	HERB MARKER BASIL
1058	22102	1622	720.0	0.443896	MIRROR MOSAIC T-LIGHT HOLDER
1249	22313	565	250.0	0.442478	OFFICE MUG WARMER PINK
1061	22105	574	240.0	0.418118	MIRROR MOSAIC GOBLET CANDLE HOLDER
119	18097C	699	292.0	0.417740	WHITE TALL PORCELAIN T-LIGHT HOLDER

Observamos

- El análisis de tasa de cancelación por producto revela problemas puntuales: varios ítems superan 100 % (p. ej., IVORY CHANDELIER T-LIGHT HOLDER ≈166 % y TEA TIME PARTY BUNTING ≈132 %), lo que implica más unidades devueltas que vendidas en el periodo. El grupo con mayor incidencia son

accesorios de iluminación y decoración (candelabros, t-light holders, photoframes), además de algunos códigos “Manual”, lo que sugiere errores de picking/codificación, expectativa vs. realidad en el producto o estacionalidad mal calibrada. Recomendación rápida: auditar fichas y fotos, revisar calidad/packaging y vigilar reposiciones para evitar sobrestock en artículos con cancelación crónica.

VI. Insigth

El driver del Revenue es el volumen

Quantity tiene correlación fuerte con Revenue ($\rho \approx 0.65$) y UnitPrice solo moderada ($\rho \approx 0.35$); variables de calendario aportan poco. VIF ~ 1 en todos los predictores (sin multicolinealidad).

Acción: optimiza upsell/bundles y “multi-unidad” (mínimos de compra, packs) para elevar cantidad por ticket.

Dos arquetipos de mercado, estrategias distintas

UK: muchísimo volumen pero AOV bajo (≈ 418 ; burbuja más grande por revenue total). Singapore/Netherlands/Australia: AOV alto ($\sim 2.5\text{--}3.0\text{k}$) con bajo volumen. Acción: en UK empuja bundles, cross-sell y suscripciones; en mercados premium enfoca adquisición/penetración y cuentas corporativas.

Temporalidad operativa clara

Picos semanales y mensuales en Q4 (sep–nov); viernes y 07:00 marcan máximos diarios/horarios. Acción: refuerza inventario, marketing y personal en Q4, especialmente viernes y primeras horas; programa campañas y drops a las 07:00.

Liderazgo de productos es rotativo y estacional Mes a mes cambian los #1 (ej. “Medium Ceramic Top Storage Jar” en ene-2011; “Rabbit Night Light” en dic-2011). Acción: mantén portafolio dinámico y planeación por Top-3 por mes/país.

Alertas críticas de cancelación/devolución por SKU

Varios productos exhiben tasas $>100\%$ (p.ej., IVORY CHANDELIER T-LIGHT HOLDER $\approx 166\%$), concentrados en iluminación/decoración. ➡ Acción inmediata: auditoría de calidad/fichas/fotos, revisar packaging y códigos; ajustar precios/stock o discontinuar; política de devoluciones específica para esos SKUs.